


AWS Machine Learning Foundations

De datos a decisiones: arquitectura, producción y gobernanza para proyectos ML escalables



Democratización del ML

Servicios gestionados para
escalar sin fricción
operativa



MLOps en Producción


Ciclos repetibles: datos,
training, deployment y
monitoreo



Gobernanza y confianza

Seguridad, trazabilidad y
explicabilidad

Por qué Machine Learning en AWS



Escalabilidad: Infraestructura elástica para entrenar y servir modelos

- Cómputo bajo demanda para entrenamiento e inferencia
- Escalado según volumen de datos, tráfico y complejidad del modelo.



Servicios gestionados: Menos infraestructura, más foco en el caso de negocio

- AWS reduce el undifferentiated heavy lifting operativo.
- Equipos se enfocan en datos, modelos y decisiones, no en administrar servidores.



Integración de datos: Del data lake al modelo dentro de un ecosistema conectado

- Amazon S3 como base del data lake y repositorio de artefactos
- Integración con Glue, Athena, Kinesis y SageMaker



Producción y MLOps: Del prototipo al despliegue con mayor velocidad y control

- Soporte para entrenamiento, despliegue, monitoreo y retraining.
- Reducción del TTM con flujos repetibles y observables


Del problema de negocio a problema ML

El éxito de un proyecto de ML comienza cuando un objetivo de negocio se traduce en una pregunta analítica medible, una tarea de ML correcta y una decisión accionable.



Ciclo de vida ML

ML no termina en el despliegue: Es un ciclo continuo que conecta negocio, datos, modelo, operación y mejora.



Servicios AWS Principales para ML

Datos: Amazon S3, Amazon RDS, Amazon Redshift, DynamoDB

Base para almacenar datos estructurados, semiestructurados y no estructurados

Procesamiento y preparación: AWS Glue, Amazon Athena, EMR, Kinesis

Ingesta, catálogo, transformación, exploración y preprocesamiento batch/streaming

ML Platform: Amazon SageMaker AI

Notebooks, training jobs, tuning, pipelines, feature store y model registry

Despliegue e inferencia: SageMaker Endpoints, Batch Transform, API Gateway, Lambda

Inferencia real-time, batch, asíncrona e integración con aplicaciones

Monitoreo y observabilidad: Amazon CloudWatch, SageMaker Model Monitor, EventBridge, SNS

Métricas, logs, drift, alertas y respuestas operativas

Seguridad y gobernanza: IAM, KMS, CloudTrail, VPC, Secrets Manager

Control de acceso, cifrado, auditoría, red privada y gestión segura de credenciales

Rol de Amazon SageMaker AI



Fundamentos de datos: de datos crudos a features entrenables

Antes de entrenar un modelo, AWS ayuda a convertir datos crudos en datasets confiables, representativos y listos para aprendizaje.

1. Fuentes de datos

Sistemas que generan señales

- IoT, apps, logs, bases transaccionales, CRM, ERP
- Datos estructurados, semiestructurados y no estructurados

2. Data Lake

Repositorio central de datos y artefactos

- Datos crudos, procesados y curados
- Base para desacoplar almacenamiento y cómputo.

3. ETL, catálogo y calidad

AWS Glue + Athena

- Limpieza, validación, imputación y unión de fuentes.
- Eliminación de datos inútiles: IDs, nombres o campos sin señal predictiva

4. Feature Engineering

Transformar datos en señales para el modelo

- One-Hot Encoding para variables nominales
- Binning para variables continuas
- Normalización para escalado numérico
- Mapping para variables ordinales


5. Dataset de entrenamiento

Datos listos para aprender y generalizar

- Features + label
- División train/test
- Dataset trazable, consistente y estadísticamente útil

Entrenamiento, tuning y evaluación

Entrenar un modelo no es solo ajustar parámetros: Es validar que generalice, comparar versiones y registrar solo modelos listos para producción



Resultado	Señal	Acción
Underfitting	Alto error en train y test	Modelo muy simple; mejorar features o complejidad
Good fit	Buen desempeño en train y test	Candidato para registrar
Overfitting	Bajo error en train, alto error en test	Regularizar, reducir complejidad o mejorar datos


Fundamentos de despliegue: batch, real-time y async

No todos los modelos deben desplegarse como endpoints 24/7. La arquitectura correcta depende de cuándo se necesita la predicción, cuánto pesa la entrada y cuánto estamos dispuestos a pagar por disponibilidad

Criterio operativo	Real-time inference	Asynchronous inference	Batch inference / Batch Transform
Necesidad de respuesta	Inmediata	Near real-time	Programada / diferida
Latencia esperada	Milisegundos / segundos	Minutos, hasta procesos largos	Minutos u horas según volumen
Tamaño de payload	Pequeño o moderado	Grande, hasta 1 GB	Masivo, lotes completos
Patrón de tráfico	Constante o interactivo	Ráfagas, cargas pesadas o irregulares	Ejecuciones programadas
Infraestructura	Endpoint activo	Cola + Proesamiento gestionado	Job efímero sin endpoint persistente
Optimización de costo	Mayor costo si está 24/7	Puede escalar a cero	Para por ejecución del lote
Caso ideal	Fraude, recomendación, scoring online	Imágenes pesadas, documentos, payloads grandes	Forecasting, churn scoring, reportes diarios

Fundamentos de monitoreo MLOps

Un modelo en producción debe observarse continuamente para detectar drift, degradación y riesgos operativos antes de que impacten al negocio



Gobernanza, seguridad y explicabilidad del ML

Un modelo productivo no solo debe predecir bien: Debe ser seguro, trazable, explicable y aprobable antes de generar impacto en el negocio

1. Seguridad y control de acceso

IAM + cifrado + auditoría

- Acceso con principio de mínimo privilegio
- TLS en tránsito y KMS en reposo para proteger datos y artefactos
- Auditoría y trazabilidad de acciones con CloudTrail

2. Explicabilidad y sesgo

SageMaker Clarify

- Explicabilidad local y global con valores tipo SHAP/Shapley
- Detección de sesgos en datos y modelos
- Base para confianza, revisión regulatoria y Responsible AI

3. Trazabilidad y promoción del modelo

SageMaker Model Registry

- Versionado de artefactos, métricas y metadatos
- Estados de aprobación antes de promover a producción
- Control de qué versión fue desplegada y por qué


4. Documentación y accountability

Model Cards / documentación del modelo

- Propósito, datos de entrenamiento, métricas, limitaciones y riesgos
- Casos de uso permitidos y no permitidos
- Soporte para auditorías, revisión y gobernanza continua

Arquitectura de referencia ML en AWS

Una arquitectura ML productiva conecta datos, entrenamiento, registro, inferencia, monitoreo y acciones correctivas en un flujo gobernado y repetible



Caso de uso 1: Forecasting de demanda (batch)

1. Objetivo de negocio

Reducir quiebres de stock y exceso de inventario
Mejorar compras, distribución y planificación logística

2. Enmarcar problema ML

Problema: forecasting de series temporales
Predecir demanda futura por producto, tienda y fecha para decidir reposición

3. Preparar datos y features

AWS Glue consolida ventas históricas y contexto temporal
Se incorporan calendario, festividades, promociones, estacionalidad y variables operativas

4. Entrenar y evaluar

Modelo de forecasting en SageMaker
Aprende tendencia, estacionalidad y eventos especiales
Evaluación con métricas como MAPE, WAPE o RMSE

5. Desplegar e inferir

Inferencia batch / Batch Transform
Procesamiento masivo nocturno o diario sobre miles de SKU-tienda, sin endpoint 24/7

6. Monitorear y mejorar

Monitoreo de error de pronóstico y retraining programado
Se revisa degradación del forecast, cambios en demanda y necesidad de recalibración

Caso de uso 2: Detección de fraude (real-time)

1. Objetivo de negocio

Reducir fraude con mínima fricción al cliente

Disminuir pérdidas sin bloquear demasiadas transacciones legítimas

2. Enmarcar problema ML

Problema: clasificación binaria / scoring de riesgo

Estimar la probabilidad de fraude para decidir aprobar, bloquear o revisar

3. Preparar datos y features

Enriquecimiento en línea con Lambda + DynamoDB

Se agregan perfiles del cliente, historial, frecuencia, monto, comercio, ubicación y dispositivo

4. Entrenar y evaluar

Modelo de clasificación en SageMaker

Aprende patrones de fraude sobre datos desbalanceados

Evaluación con Recall, Precision, F1-score y PR AUC (Conviene no depender de Accuracy)

5. Desplegar e inferir

SageMaker real-time endpoint

Scoring en milisegundos para responder durante la transacción

6. Monitorear y mejorar

CloudWatch + Model Monitor

Se observa latencia, errores, drift, falsos positivos y falsos negativos

Se ajustan umbrales, se hace retraining o se prueba una nueva versión