

Entrenamiento y optimización de modelos en AWS

De datos preparados a modelos reproducibles, escalables y listos para producción con Amazon SageMaker



Calidad predictiva

Entender cómo el entrenamiento transforma datos históricos en patrones capaces de generalizar sobre nuevos casos



Eficiencia operativa

Usar SageMaker para desacoplar cómputo y almacenamiento, ejecutar jobs efímeros y optimizar tiempo, escala y costo



Gobernanza y MLOps

Rastrear experimentos, métricas, hiperparámetros y artefactos para llevar el mejor modelo hacia Model Registry y producción

Por qué el entrenamiento de modelos importa

Del dato histórico al artefacto predictivo que aprende, generaliza y genera valor.

Desempeño Predictivo

Foco: Minimizar el error relevante

Ajustar pesos y sesgos para reducir la función de pérdida y mejorar la métrica correcta del problema.

Generalización

Foco: Aprender, no memorizar

Balancear bias y varance para evitar underfitting y overfitting sobre datos no vistos.

Confiabilidad Operativa

Foco: Reproducibilidad y control

Separar entrenamiento, evaluación y tuning para comparar resultados y reconstruir el artefacto generado.

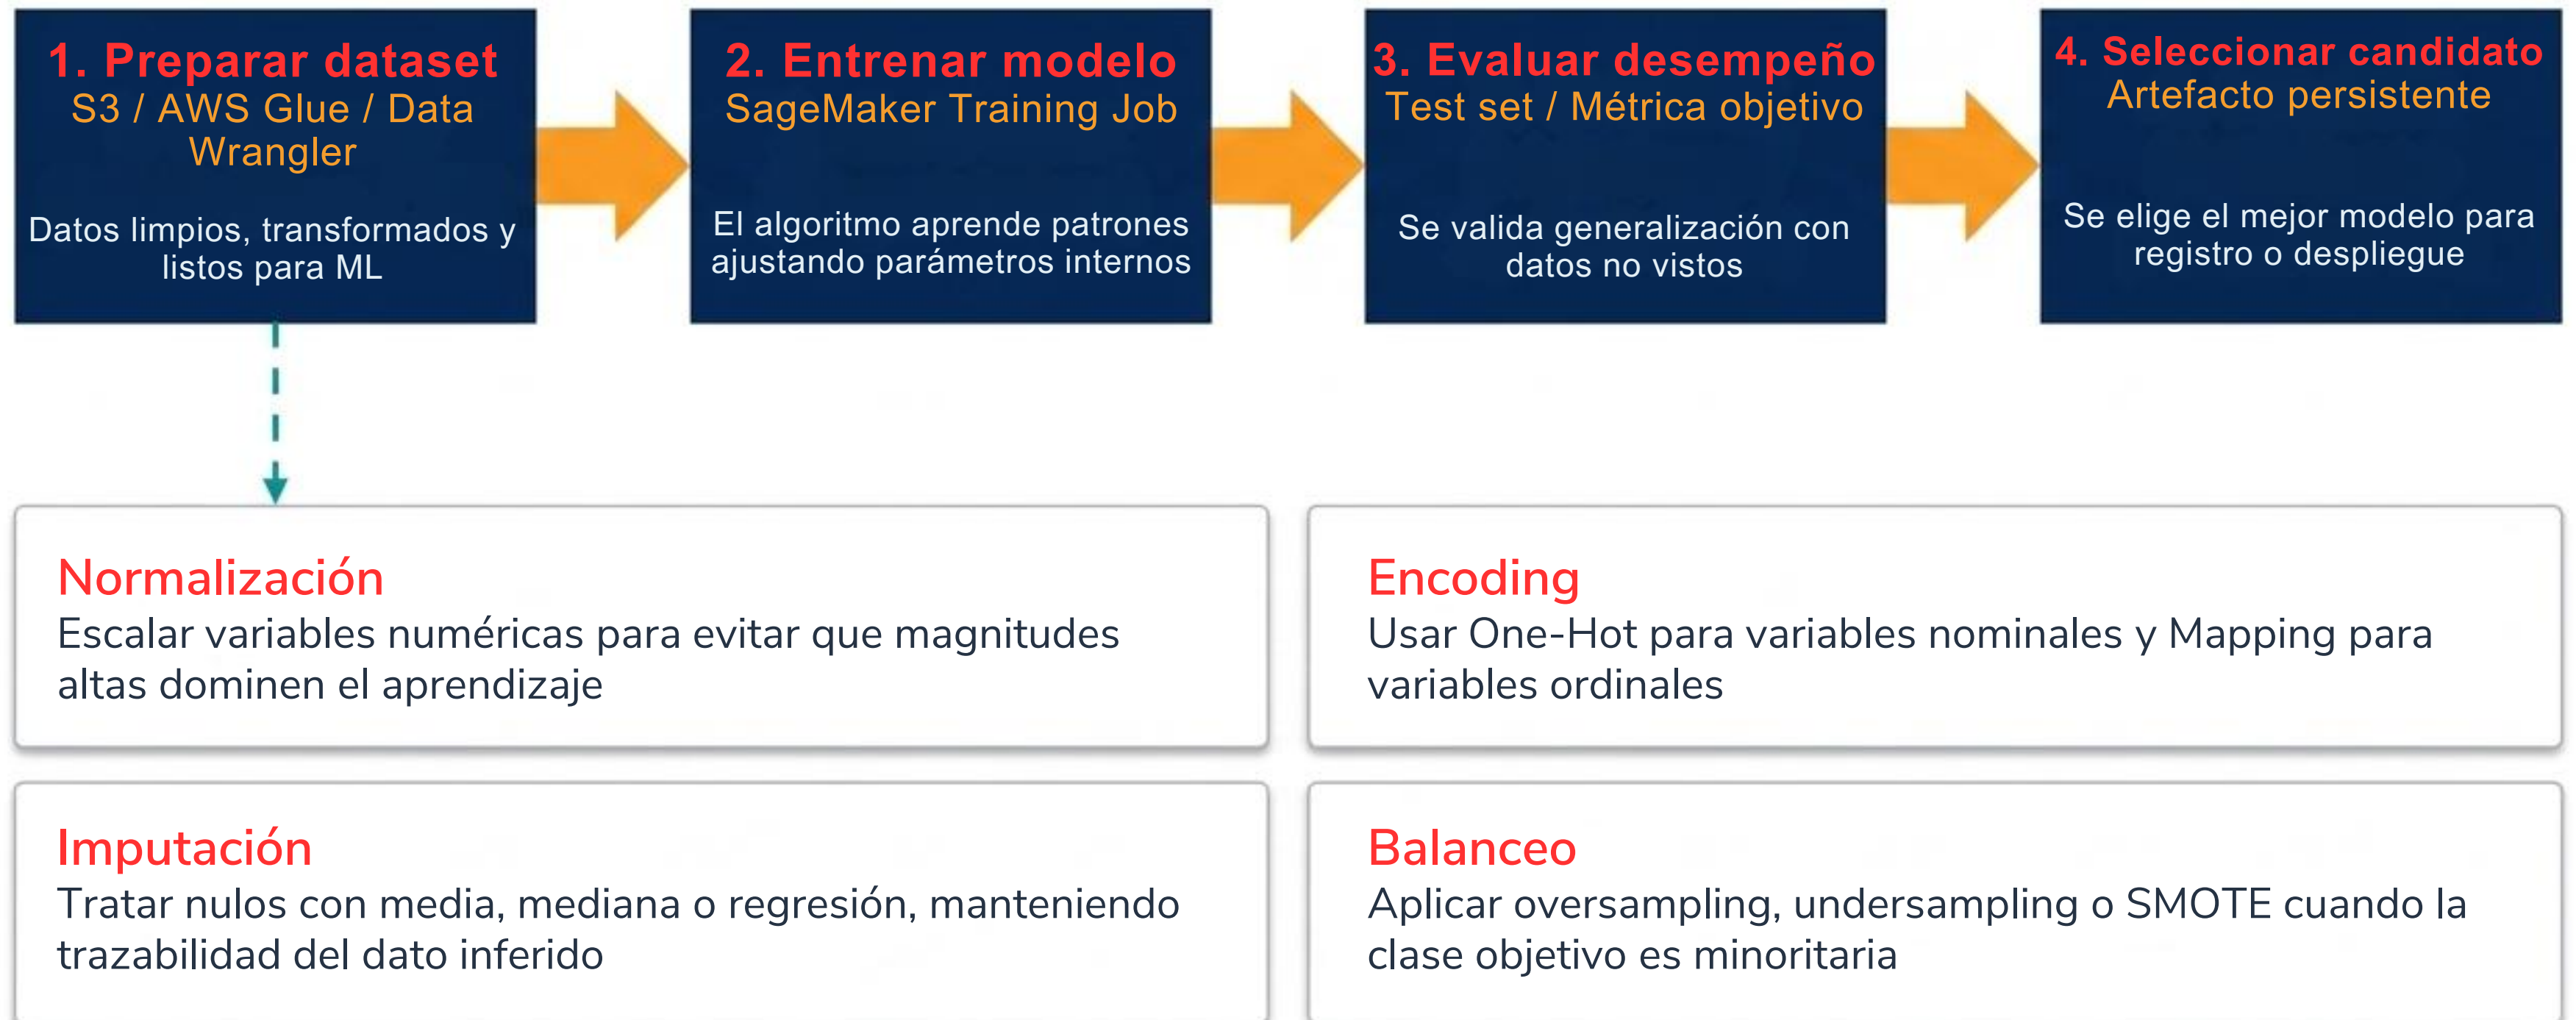
Valor de negocio

Foco: Decisiones escalables

Convertir patrones históricos en predicciones útiles para casos como fraude, churn, riesgo o diagnóstico.


De datos preparados a modelo entrenado

La calidad del modelo depende de cómo convertimos datos crudos en señales útiles para aprender



Arquitectura de SageMaker Training Jobs

Entrenamiento gestionado y efímero: datos en S3, cómputo bajo demanda y artefactos persistentes



Built-in Algorithms vs Custom Training Scripts

Elegir entre velocidad operativa, flexibilidad de código y control del entorno de entrenamiento

Enfoque	Flexibilidad	Velocidad	Esfuerzo operativo	Caso de uso ideal
Built-in Algorithms	Media-baja	Muy alta	Bajo	Clasificación, regresión, forecasting o reducción dimensional con algoritmos estándar
Script Mode	Alta	Media	Medio	Entrenamiento con PyTorch, TensorFlow o Scikit-learn usando código propio
BYOC (Bring Your Own Container)	Máxima	Baja-media	Alto	Librerías propietarias, lenguajes no soportados o investigación avanzada

Métricas y estrategia de evaluación

La mejor métrica no es la más popular, sino la que refleja el costo real del error

Clasificación balanceada

Contexto:

Clases con proporciones similares

Métrica:

Accuracy, Precision, Recall

Alerta:

Útil cuando falsos positivos y falsos negativos tienen impacto similar

Clasificación desbalanceada

Contexto:

Fraude, churn, riesgo, diagnóstico

Métrica:

F1 Score, Recall, Precision, AUC

Alerta:

Accuracy puede ocultar fallas críticas en la clase minoritaria

Regresión

Contexto:

Demanda, precios, tallas, tiempos

Métrica:

MAE, MSE, RMSE

Alerta:

MSE/RMSE penalizan más los errores grandes y son sensibles a outliers.

Forecasting / Series temporales

Contexto:

Demanda, inventario, ventas, capacidad

Métrica:


MAE, RMSE, MAPE o WAPE

Alerta:

El split debe ser cronológico, no se debe mezclar el futuro con el pasado.

Hiperparámetros y optimización

Configuraciones externas que controlan cómo aprende el modelo antes de iniciar el entrenamiento



1. Hiperparámetros

Decisiones antes de entrenar

- Learning rate
- Batch size
- Número de épocas
- Profundidad de árboles
- Regularización
- Early stopping

Definen la velocidad, complejidad y estabilidad del aprendizaje.

2. Entrenamiento

El modelo aprende parámetros internos

- Ajusta pesos y sesgos
- Reduce la función de pérdida
- Busca patrones en los datos
- Genera un artefacto entrenado

El algoritmo aprende parámetros internos usando las reglas definidas.

3. Performance


Resultado medido con una métrica objetivo

- Accuracy, F1, AUC
- MAE, RMSE
- Costo y tiempo de entrenamiento
- Riesgo de overfitting o underfitting

La combinación correcta mejora la métrica objetivo y la capacidad de generalizar.


SageMaker Automatic Model Tuning - HP0

Automatizando la búsqueda de hiperparámetros para maximizar la métrica objetivo con menos prueba manual.



Experiment Tracking con SageMaker Experiments

Trazabilidad de cada experimento: datos, código, parámetros, métricas y artefactos.



Optimización de costos en entrenamiento

Reducir TCO equilibrando precio de cómputo, tiempo de entrenamiento, resiliencia y eficiencia de datos.



Managed Spot Training

Usa capacidad EC2 disponible para reducir costos de entrenamiento, especialmente en experimentación, HPO y jobs tolerantes a interrupciones.

Clave: ideal cuando el entrenamiento puede reanudarse.



Checkpoints en S3

Guarda periódicamente el estado del entrenamiento para retomar desde el último avance si la instancia Spot es reclamada.

Clave: sin checkpoints persistidos en S3, Spot puede hacerte perder progreso.



Right-Sizing & Profiler

Selecciona CPU, GPU, memoria y almacenamiento según la carga real. Usa Profiler para detectar cuellos de botella y recursos subutilizados.

Clave: una GPU cara subutilizada también es desperdicio.



Pipe Mode & Reutilización


Reduce descargas iniciales y uso de EBS leyendo datos desde S3 por streaming cuando aplique. Reutiliza resultados previos de tuning con warm start.

Clave: menor startup time, menos I/O y menos trials innecesarios.

Distributed Training y escalabilidad

Escalar el entrenamiento cuando una sola instancia ya no alcanza: Por datos masivos o modelos demasiado grandes

Data Parallelism (SMDDP)




Cuándo usarlo: Dataset masivo; el modelo sí cabe completo en cada GPU o instancia

Cómo funciona: El dataset se divide entre múltiples nodos. Cada nodo entrena una réplica del mismo modelo con una parte de los datos

Resultado esperado: Reduce el tiempo de entrenamiento al procesar datos en paralelo

Model Parallelism (SMP)




Cuándo usarlo: Modelo demasiado grande para una sola GPU o instancia.

Cómo funciona: El modelo se divide en partes distribuidas entre múltiples GPUs o nodos. Los datos atraviesan esas particiones durante el entrenamiento.

Resultado esperado: Permite entrenar arquitecturas grandes que no caben en una sola memoria.


Del mejor modelo al Model Registry

Gobernar el paso a producción: Evaluación final, aprobación, versionado y promoción controlada.



Automatización con SageMaker Pipelines

MLOps nativo: Convertir entrenamiento, evaluación y registro en un flujo repetible y auditable



Garantiza consistencia operacional: cada ejecución sigue los mismos pasos, criterios y evidencias

Caso de uso: Optimización de modelo de Churn

Arquitectura end-to-end para retención proactiva: De señales de engagement a acciones personalizadas.

